Jurnal Teknologi Informasi dan Ilmu Komputer (JTIIK) DOI: 10.25126/jtiik...
Vol. x, No. x, April 2014, hlm. x-x p-ISSN: 2355-7699
Akreditasi KEMENRISTEKDIKTI, No. 36/E/KPT/2019 e-ISSN: 2528-6579

Addressing Outliers in Customer Segmentation: Comparative Effectiveness Of K-Prototype Clustering and Mix Type DBSCAN

Kartika Nur Rahma[1], Andriano[2], Shinta Istibsyaroh Umami[3], Heri Kuswanto[4]

[1,2,3,4] Departemen Statistika, Institut Teknologi Sepuluh Nopember, Kampus ITS – Sukolilo, Surabaya 60111, Indonesia
Email: [1]6003231031@student.its.ac.id, [2]6003231006@student.its.ac.id, [3]6003231010@student.its.ac.id, [4]heri_k@statistika.its.ac.id

Abstrak

Toko suplemen telah menjadi komponen penting dalam ekosistem kesehatan dan kebugaran. Pada sektor ritel industri suplemen, telah mengalami pertumbuhan yang signifikan selama dekade terakhir. Di Indonesia pertumbuhan industri suplemen juga dipengaruhi oleh beberapa fenomena yang memerlukan perhatian khusus. Ini menuntut para pelaku bisnis untuk terus berinovasi dan menawarkan produk serta layanan yang dapat memenuhi ekspektasi konsumen. Dibalik peluang kesempatan perkembangan bisnis pada industri ini, tentu terdapat banyak tantangan dibelakangnya diantaranya ialah segmentasi pasar yang kompleks. Untuk mengatasi tantangan-tantangan tersebut, toko suplemen di Indonesia perlu mengadopsi pendekatan analisis yang lebih canggih dalam memahami pelanggan mereka. Metode statistik yang dapat diandalkan ialah K-prototype *Clustering* dan MT-DBSCAN *clustering*. K-prototype *cluster*ing adalah metode segmentasi yang menggabungkan variabel numerik dan kategorikal dalam analisis *cluster*ing. Sedangkan MT-DBSCAN *clustering* merupakan penggabungan metode Gower's *Distance* dengan metode DBSCAN *clustering* yang bisa digunakan untuk melakukan segmentasi dari data campuran (*mix type* data). Kedua metode ini sangat cocok untuk industri toko suplemen yang memiliki data konsumen yang bervariasi. Data yang digunakan dalam analisis ini merupakan data skunder yang diambil langsung oleh sistem melalui 2 platform channel e-commerce yaitu Toko Hijau dan Toko Biru. Hasil menunjukkan bahwa Metode MT-DBSCAN merupakan metode yang lebih baik jika data yang digunakan terdapat outliers, hal tersebut dikarenakan pada algoritma MT-DBSCAN menggunakan Gowers *Distance* yang robust terhadap outliers. Sedangkan, jika outliers dalam data diatasi atau data tidak mengandung outliers maka metode clustering yang lebih baik adalah K-Protoype dengan banyak cluster yang terbentuk ialah 2 cluster.

Kata kunci: Industri suplemen, K-prototype *clustering*, MT-DBSCAN, segmentasi pelanggan, Gower's *distance.*

Addressing Outliers In Customer Segmentation: Comparative Effectiveness Of K-Prototype Clustering And Mix Type DBSCAN

Abstract

Supplement stores have become an important component in the health and fitness ecosystem. The retail sector of the supplement industry has experienced significant growth over the last decade. The growth of the supplement industry in Indonesia is also influenced by several phenomena that require special attention. This requires businesspeople to continue to innovate and offer products and services that can meet consumer expectations. Behind the opportunities for business development in this industry, of course there are many challenges behind them, including complex market segmentation. To overcome these challenges, supplement stores in Indonesia need to adopt a more sophisticated analytical approach in understanding their customers. The statistical methods that can be taken are K-prototype Clustering and MT-DBSCAN clustering. K-prototype clustering is a segmentation method that combines numerical and categorical variables in clustering analysis. Meanwhile, MT-DBSCAN clustering is a combination of the Gower's Distance method with the DBSCAN clustering method which can be used to segment mixed data (mix type data). This second method is very suitable for the supplement store industry which has varied consumer data. The data used in this analysis is secondary data taken directly by the system via 2 e-commerce channel platforms, namely Toko Hijau and Toko Biru. The results show that the MT-DBSCAN method is a better method if the data used contains outliers, this is because the MT-DBSCAN algorithm uses Gowers Distance which is strong against outliers. Meanwhile, if outliers in the data are resolved or the data does not contain outliers, a better clustering method is K-Protoype with the number of clusters formed, namely 2 clusters.

Keywords: *The supplement industry*, *K-prototype clustering,* MT-DBSCAN, *customer segmentasi,* Gower's *Distance.*

1. PENDAHULUAN

Seiring dengan meningkatnya kesadaran konsumen akan kesehatan dan kebugaran, permintaan akan suplemen makanan juga meningkat. Toko suplemen telah menjadi komponen penting dalam ekosistem kesehatan dan kebugaran. Pada sektor ritel industri suplemen, telah mengalami pertumbuhan yang signifikan selama dekade terakhir. Menurut sebuah laporan oleh Grand View Research (2020), pasar suplemen global diperkirakan akan mencapai nilai USD 278.02 miliar pada tahun 2024 dengan tingkat pertumbuhan tahunan gabungan (CAGR) sebesar 8.2% dari tahun 2019 hingga 2024. Tren ini juga terlihat di Indonesia, di mana industri suplemen kesehatan menunjukkan pertumbuhan yang signifikan seiring dengan meningkatnya kesadaran masyarakat akan gaya hidup sehat. Sebuah studi oleh Nielsen (2019) menunjukkan bahwa konsumen Indonesia semakin sadar akan kesehatan dan lebih memilih produk yang mendukung kesehatan mereka Dengan penawaran produk yang begitu beragam, memahami preferensi dan perilaku pembelian konsumen sangat penting bagi bisnis yang beroperasi di sektor ini.

Permintaan akan berbagai jenis suplemen, mulai dari vitamin, mineral, hingga produk-produk herbal dan protein menyebabkan berjamurnya toko-toko ini yang berbasis offline maupun online. Pertumbuhan industri suplemen juga dipengaruhi oleh beberapa fenomena yang memerlukan perhatian khusus. Pertama, terdapat diversifikasi yang luas dalam preferensi konsumen terkait jenis suplemen yang mereka butuhkan, tergantung pada faktor-faktor seperti usia, jenis kelamin, gaya hidup, dan kondisi kesehatan. Kedua, dengan semakin banyaknya pemain di pasar, persaingan antar toko suplemen menjadi semakin ketat. Ini menuntut para pelaku bisnis untuk terus berinovasi dan menawarkan produk serta layanan yang dapat memenuhi ekspektasi konsumen.

Namun dibalik peluang kesempatan perkembangan bisnis pada industri ini, tentu terdapat banyak tantangan dibelakangnya diantaranya ialah segmentasi pasar yang kompleks. Mengingat keragaman demografis dan psikografis konsumen di Indonesia, melakukan segmentasi pasar yang tepat menjadi sebuah keharusan. Segmentasi pasar yang baik memungkinkan toko suplemen untuk lebih memahami kebutuhan dan preferensi berbagai kelompok konsumen, sehingga dapat menyusun strategi pemasaran yang lebih efektif. Selain itu, keterbatasan data juga seringkali menjadi kendala bagi para pelaku bisnis. Data yang tidak lengkap dan tidak terstruktur dapat menghambat upaya segmentasi yang akurat. Belum lagi dengan persaingan bisnis yang ketat. Harga bisa jadi salah satu faktor alasan kenapa customer akhirnya memutuskan untuk membeli di toko tertentu.

Untuk mengatasi tantangan-tantangan tersebut, toko suplemen di Indonesia perlu mengadopsi pendekatan analisis yang lebih canggih dalam memahami pelanggan mereka. Metode statistik yang dapat diandalkan ialah K-prototype *Clustering* dan MT-DBSCAN *clustering*. K-prototype *cluster*ing adalah metode segmentasi yang menggabungkan variabel numerik dan kategorikal dalam analisis *cluster*ing. Sedangkan MT-DBSCAN *clustering* merupakan penggabungan metode Gower's *Distance* dengan metode DBSCAN *clustering* yang bisa digunakan untuk melakukan segmentasi dari data campuran (*mix type* data). Kedua metode ini sangat cocok untuk industri toko suplemen yang memiliki data konsumen yang bervariasi, seperti data demografi (usia, jenis kelamin), preferensi produk, dan riwayat pembelian. Dengan kedua metode tersebut, toko suplemen dapat mengelompokkan pelanggan mereka ke dalam segmen-segmen yang lebih homogen, sehingga memudahkan dalam penyusunan strategi pemasaran yang lebih tepat sasaran.

2. TINJAUAN PUSTAKA

2.1 Analisis *Cluster*

Analisis *cluster* merupakan salah satu analisis statistik yang berguna untuk membagi komponen pada suatu data set sehingga komponen yang memiliki kemiripan ditempatkan pada kelompok atau *cluster* yang sama. Tujuan dari analisis *cluster* adalah untuk menemukan komponen dalam suatu data set secara efesien (Xu & Wunsch, 2005). Analisis *cluster* membuat suatu kumpulan data menjadi homogen antar pengamatan dan heterogen antar kelompok. Analisis *cluster* memegang peran penting dalam pengolahan *big data* karena penggalian informasi pada analisis *big data* sangat sulit dilakukan sehingga dibutuh metode penggalian informasi yang tersebunyi dari suatu data set yang besar atau biasa disebut *data mining* salah satunya adalah menggunakan analisis *cluster.* Berdasarkan hal tersebut, analisis *cluster* merupakan salah satu metode *data mining* yang berguna untuk menggabungkan objek – objek pada satu kelompok atau *cluster* berdasarkan kemiripan antar observasi yang dinilai berdasarkan atribut yang mendeskripsikan suatu objek (Erilli, 2019).

2.2 Outliers

Outlier atau pencilan merupakan data atau pengamatan yang memiliki nilai yang sangat berbeda

dari pengamatan lainnya. Adanya *outlier* disebabkan juga oleh beberapa hal seperti kesalahan pengukuran, kesalahan pada data, kejadian langka, dan beberapa penyebab lainnya. Pendeteksian *outlier* bisa dilakukan dengan beberapa cara, yang paling umum digunakan adalah metode grafik dengan boxplot, dengan statistik deskriptif *Z-score* dan *Interquartile Range* (IQR), dan pengujian statistik Grubb's test, Dixon test. Data yang mengandung *outlier* akan menyeybabkan hasil analisis yang tidak baik sehingga harus ditangani. Penanganan *Outlier* terdapat beberapa cara yaitu mengahpus *outlier* tersebut, transformasi, imputasi dan *winsorizing* (Dash et al., 2023). Namun jika menggunakan teknik penghapusan *outlier,* kumpulan data yang memiliki banyak *outlier* akan kehilangan banyak informasi terkait data tersebut. Sebagai alternatifnya bisa mengggunakan *winsorizing*.

2.3 *Winsorizing*

Winsorizing merupakan salah satu teknik penanganan data yang terdapat *outlier* yang mana teknik ini mengganti *outlier* menjadi data persentil ke-5 untuk *outlier* yang berada dibawah data minimum dan persentil ke-95 untuk data yang berada diatas maksimum. Batas persentil tersebut dapat disesuaikan tergantung pada kebutuhan data yang digunakan (Sihombing et al., 2023). Penanganan *outlier* dengan *winsorizing* dilakukan seolah – olah data *outlier* tersebut merupakan *missing value* sehingga *outlier* tersebut digantikan dengan data asli yang terdapat pada kumpulan data tersebut.

2.4 Ukuran Kemiripan

Pada analisis *cluster* membutuhkan beberapa ukuran kemiripan untuk mengetahui seberapa mirip suatu observasi terhadap observasi lainnya yang kemudian akan dikelompokkan pada *cluster* yang sama. Untuk mengukur hal tersebut terdaoat tiga cara yaitu korelasi, ukuran asosiasi, dan ukuran jarak. Pada ukuran korelasi hanya bisa digunakan untuk data dengan skala metrik dengan kemiripan antar observasi dilihat dari koefisien korelasi antar pasangan objek yang diukur pada beberapa variabel. Ukuran asosiasi digunakan untuk data dengan skala nonmetric. Sednagkan ukuran jarak merupakan ukuran kemiripan berdasarkan jarak untuk data berskala metrik dimana semakin kecil jaraknya maka semakin mirip antar observasi tersebut (Novidianto & Fithriasari, 2021). Pada analisis *cluster* menggunakan ukuran kemipira jarak. Ada beberapa metode pengukuran jarak salah satunya adalah jarak *eucledian.* Jarak *eucledian* adalah perhitungan jarak dari dua titik dalam *eucledian space.* Perhitungan jarak *eucledian* pada data numerik dijabarkan pada persamaan berikut (Cormen et al., 2001):

$$d_r(X_j, Z_i) = \sqrt{\sum_{i=1}^{n} (x_{jk} - z_{ik})^2} \qquad (1)$$

dimana x_{jk} merupakan nilai pada atirbut numerik k pada kelompok ke-i dan z_{ik} merupakan rata -rata atau *prototype* atribut numerik k pada kelompok ke i. sedangkan perhitungan jarak *eucledian* pada data kategorik dijabarkan pada persamaan berikut (Dake et al., 2023):

$$d_c(X_j, Z_i) = \gamma_i \sum_{p=k+1}^{m} \delta(x_{jk}, z_{ik}) \qquad (2)$$

Serta *simple matching similarity measure* pada data kategorik adalah sebagai berikut:

$$\delta(x_{jk}, z_{ik}) = \begin{cases} 0, (x_{jk} = z_{ik}) \\ 1, (x_{jk} \neq z_{ik}) \end{cases} \qquad (3)$$

dimana γ_i merupakan Bobot untuk data kategorik pada kelompok ke I diperoleh dari nilai standar deviasi untuk atribut numerik pada masing – masing kelompok. untuk x_{jk} yang merupakan nilai atribut pada data kategori, z_{ik} merupakan modus pada variabel k kelompok ke i. sehingga untuk persamaan (1) dan persamaan (2) Ketika dikombinasikan maka ukuran kesamaan data yang memiliki variabel katgeorik dan numerik dijabarkan pada persamaan berikut:

$$d(X_j, Z_i) = \sqrt{\sum_{i=1}^{n} (x_{jk} - z_{ik})^2 + \gamma_i \sum_{p=k+1}^{m} \delta(x_{jk}, z_{ik})} \qquad (4)$$

2.5 Metode Elbow

Metode elbow merupakan salah satu teknik penentuan jumlah *cluster* atau kelompok pada analisis *cluster.* Dalam menentukan jumlah *cluster (k)* metode elbow menggunakan pendekatan dimana jumlah k dipilih berdasarkan kondisi terjadi penurunan secara drastis dengan sebuah lekukan yang tajam pada suatu grafik. Pencarian k yang paling optimum dilakukan dengan membandingkan nilai *Sum of Square Error* (SSE) terkecil yang disajikan pada grafik. Langkah – langkah dalam menentukan k optimum dengan metode elbow adalah sebagai berikut (Kaufman & Rousseeuw, 2005):

1. Menentukan insialisasi awal untuk nilai k.
2. Meningkatkan nilai k sampai jumlah *cluster* yang telah ditentukan
3. Melakukan perhitungan nilai SSE pada setiap k dengan persamaan berikut:

$$SSE = \sum_{k=1}^{n} \sum_{x_i \in s_k} \left| |X_i - C_k| \right|_2^2 \quad (5)$$

Dimana X_i merupakan observarsi ke-*i* dan C_k adalah banyaknya *cluster i* pada *cluster* ke-*k.*

4. Menganalisis nilai SSE yang telah diperoleh dari setiap *n cluster.*
5. Menentukan jumlah *cluster* berdasarkan penurunan SSE yang paling drastis.

2.4 Algorima *K-Prototype*

Algoritma *K-Prototype* merupakan salah satu analisis *cluster* yang mana data merupakan campuran antara data numerik dan kategorik. Algorima ini merupakan campuran dari *K-means* dan *K-Modes* yang mana berturut – turur merupakan analisis *cluster* yang digunakan pada data numerik dan kategorik. Algoritma ini memiliki langkah yang sangat sederhana dan mampu menggali informasi yang cukup dalam pada *big data analysis. K-Prototype* merupakan salah satu analisis *cluster* nonhirarki yang dapat membagi objek – objek ke dalam kelompok berdasarkan kemiripan karakteristik tertentu. Langkah – langkah dalam analisis *cluster K-prototype* adalah sebagai berikut (Huang, 1998):

1. Melakukan inisialisasi *k* awal *prototype* yaitu $Z_1, Z_2, \dots, Z_n$ sebagai pusat *cluster* pada masing – masing *cluster.*
2. Menghitung jarak insial pada masing – masing *cluster* untuk setiap observasi untuk menentukan kemiripan untuk setiap observasi dengan menggunakan persamaan (4).
3. Mengelompokkan setiap observasi ke dalam setiap *k cluster* berdasarkan jarak terdekat dengan inisial awal.
4. Melakukan *iterasi* pada langkah 1 sampai dengan langkah ke-3 hingga tidak ada perpindahan suatu observasi ke *cluster* lain atau dengan kata lain anggota *cluster* pada setiap *cluster* sudah tetap.

2.4 Algoritma MT-DBSCAN

2.4.1 Gower Distance

Gower *distance* pertama kali dikembangkan oleh Gower dimana metode ini paling umum digunakan untuk data bertipe campuran yaitu variabel numerik dan variabel kateorik. Gower *distance* menghitung jarak secara terpisah antara variabel numerik dan kategorik. Perhitungan jarak menggunakan Gower *distance* dijabarkan pada persamaan berikut (Fadilah & Wijayanto, 2023):

$$\delta_G(X,Y) = \frac{\sum_{j=1}^{m} w_j f_j(x_j, y_j)}{\sum_{i=1}^{m} w_j} \quad (5)$$

dimana $f_j(x_j, y_j) = \frac{|x_j - y_j|}{r_j}$ jika *j* berskala numerik maka r_j merupakan *range* sampel dari atribut *j* serta *simple matching* jika *j* berskala kategotik, *m* merupakan banyaknya observasi, dan w_j pembobot pada setiap atribut.

2.4.2 DBSCAN *Clustering*

Density-based spatial clustering of applications (DBSCAN) adalah salah satu akgoritma *cluster* yang menggunakan *density* yang mengidentifikasi *cluster* berdasarkan parameter *epsilon* dan minimum sampel pada satu *cluster.* Pada DBSCAN terdapat istilah *core, border,* dan *noise. Core* merupakan objek yang memenuhi memenuhi *epsilon* dan minimum sampel yang diinginkan pada satu *cluster*. Kemudian *border* merupakan objek yang berdekatan dengan *core.* Sedangkan *noise* merupakan objek yang tidak masuk kedalam *cluster* dan tersisa pada akhir pengelompokkan. Berikut langkah – langkah dalam algoritma DBSCAN *clustering:*

1. Menetapkan *epsilon* dengan menggunakan algoritma *K-Nearest Neighbors* (KNN) dan minimum sampel dalam satu *cluster.*
2. Melakukan inisialisasi untuk satu titik.
3. Menghitung matriks Gower *distance* yang digunakan untuk menghitung jarak pada variable kategorik dan variable numerik lalu hasil perhitungan ini akan disimpan kedalam matriks Gower.
4. Ekspansi *cluster* dimana langkah ini mencari semua titik yang berada radius *epsilon.*
5. Memasukkan setiap objek yang berada dalam radius *epsilon* menjadi satu *cluster.*
6. Penanganan *noise* atau yang biasa juga disebut *outlier* dapat diatasi dengan metode *winsorizing.*

3. METODE PENELITIAN

3.1 Data

Sumber Data yang digunakan dalam analisis ini merupakan data skunder yang diambil langsung oleh sistem melalui 2 platform channel e-commerce yaitu Toko Hijau dan Toko Biru. Data yang digunakan merupakan penjualan data penjualan secara online dari Perusahaan X yang dimulai dari tanggal 1 Maret 2024 hingga 15 Mei 2024 dimana banyk data ialah 3267 data.

3.2. Langkah Analisis

Untuk menjawab tujuan analisis yang telah disebeutkan sebelumnya pada pembahasan latar belakang penilitian maka metode yang tepat untuk menjawab tujuan ialah *Cluster*ing dengan K-prototype *Cluster*ing karena melibatkan data kategorik dan numerik. Berikut merupakan tahapan langkah analisis.

1. Analisa statistika deskriptif untuk melihat karakteristik data (gambaran secara umum) termasuk mendeteksi outliers.
2. Memilih variabel mana saja yang masuk dalam variabel kategorik: Provinsi, Jenis Pesanan, Toko, Channel dan Jumlah Pesanan. Sedangkan untuk variabel Numerik ialah Total penjualan, Diskon Penjual, Voucher Chanel, Biaya pengiriman, dan Berat barang (gram).
3.
   a. Untuk data kategorik, mengubah objek menjadi angka.
   b. Untuk data numerik dilakukan *feature scalling* agar memiliki skala yang sama.
4. Melakukan analisis *Cluster* dengan K-protoype *cluster*ing:
   a. Elbow Methode untuk melihat *K* (banyaknya *cluster*) yang paling optimum pada data yang ditreatment dengan *winsorizing*
   b. Penentuan K optimum dengan *elbow chart* pada data dengan *outliers.*
5. Melakukan analisis *Cluster* dengan MixType DBSCAN:
   a. Menggunakan bantuan KNN untuk nilai epsilon yang terpilih dengan data outliers.
   b. Dengan cara yang sama pada poin 5a namun dengan data tanpa outliers.
6. Membandingkan seluruh metode dengan nilai average silhoute score baik pada data dengan *outliers* dan tanpa *outliers.*
7. Visualisasi hasil klaster terbaik.

4. ANALISIS DAN PEMBAHASAN

Bab ini membahas seluruh hasil algorima *cluster*ing dengan metode yang telah dijelaskan pada tinjauan Pustaka serta langkah-langkah penelitian mengikuti metode penelitian yang telah disampaikan. Berikut merupakan hasil penelitian menggunakan bantuan *software* R dan Python.

4.1. Karakteristik Data Secara Deskriptif

Secara umum, Karakteristik penjualan supplemen pada Toko XYZ digambarkan pada chart berikut.

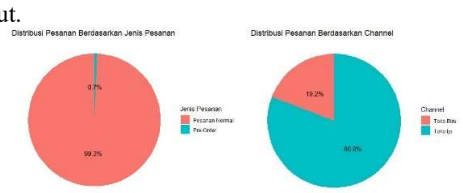

(a) (b)

Gambar 1 (a). Chart Perbandingan Penjualan Produk Berdasrkan Jenis Pesanan (b) Chart Persentase Penjualan di Channel

Berdasarkan Gambar 1 dapat diketahui bahwa dominasi prefrensi customer dalam membeli suplemen di Toko XYZ berdasarkan jenis pesanannya ialah pesanan normal dan sangat sedikit sekali yang pernah memesan pre-order. Sedangkan pada Gambar 1(b) dapat dilihat bahwa Sebagian besar customer (80,8%) berbelanja di Toko Hijau dibandingkan di Toko Biru.

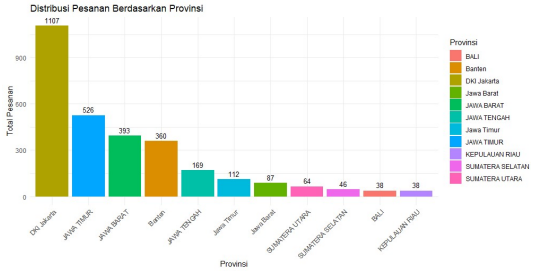

Gambar 2. Sepuluh Provinsi Tertinggi Demografi Customer

Berdasarkan gambar 2 diatas, menunjukkan bahwa customer online toko XYZ paling banyak berasal dari DKI Jakarta, disusul oleh Provinsi Jawa Timur pada urutan kedua, dan Jawa Barat pada urutan ketiga.

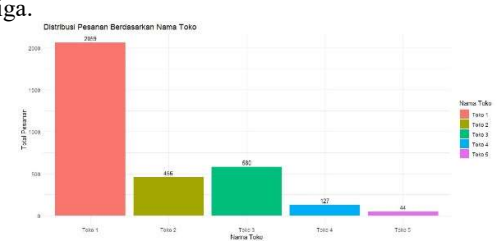

Gambar 3. Penjualan Masing-masing Toko

Gambar 3 memberikan informasi bahwa penjualan toko 1 merupakan penjualan tertinggi yang dimiliki oleh toko XYZ sedangkan penjualan paling sedikit ialah toko 4 dan 5 dengan selisih yang tidak jauh berbeda. Dari karakteristika yang tergambar, maka penelitian dilanjutkan untuk membentuk segmentasi customer dengan metode *cluster*ing.

4.2. Hasil *Clustering K-Prototype Analysis*

Salah satu metode untuk segmentasi *customer* ialah dengan metode *clustering*. Pada kasus toko supplemen XYZ ini memiliki berbagai informasi data dimana beberapa variabel bersifat numerik, sedang yang lain kategorik. Algoritma K-mean dan K-mode hanya cocok untuk masing-masing tipe data. Untuk itu, metode yang tepat untuk kedua tipe data yang disegment secara bersamaan ialah metode K-prototype dan Hierarchical *Cluster* dengan Gower *distance cluster*. Namun metode ini tidak robust pada *outlier*. DBSCAN ialah salah stau metode *cluster* yang baik untuk mengatasi data outliers, namun

metode ini hanya terbatas untuk data dengan variabel numerik. Sehingga digunakan metode kombinasi antara hierarchical *cluster* dengan Gower distance dan DBSCAN menjadi Mix Type-DBSCAN atau MT-DBSCAN dimana konsep algoritmanya ialah DBSCAN namun penentuan jaraknya menggunakan algoritma Gower distance.

4.2.1 *K-Prototype* Tanpa Data *Outliers*

Algoritma K-prototype memiliki langkah yang hampir serupa dengan K-means dan K-medoid. Untuk menentukan berapa K (banyaknya *cluster* yang optimum dapat menggunakan bantuan *Elbow Method*. Berikut merupakan output R dari nilai SSE.

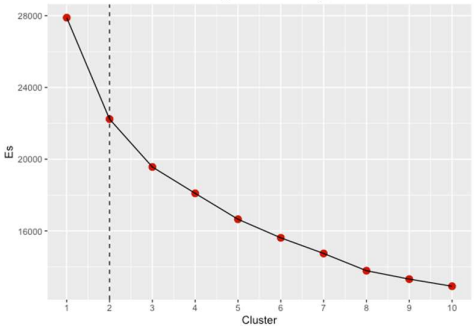

Gambar 4. *Elbow Chart* untuk Data Tanpa Outliers

Garis putus-putus (dash) pada sumbu vertical menunjukkan potongan siku (Elbow) yang menjadi salah satu cara menentukan banyaknya *cluster* yang terbentuk yaitu terdapat 2 *cluster*. Anggota pada setiap *cluster* disajikan pada tabel berikut

Tabel 1. Persebaran Anggota *Cluster*

Cluster	Banyaknya Anggota *Cluster*
1	966
2	2300

4.2.2 K-*Prototype* Dengan Data Outliers

Dengan cara yang sama pada sub 4.2.1, berikut merupakan hasil K-prototype dengan membiarkan data outliers.

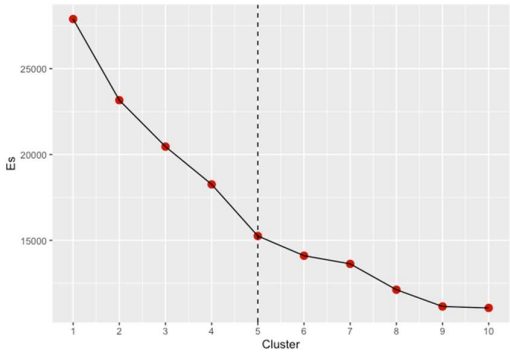

Gambar 5. *Elbow Chart* untuk Menentukan *K* Optimum

Garis putus-putus (dash) pada sumbu vertical menunjukkan potongan siku (elbow) yang menjadi salah satu cara menentukan banyaknya nilai K yang terpilih. Oleh karena itu pada kasus ini K-protoype pada data dengan outliers ialah sebanyak 5. Anggota pada setiap *cluster* disajikan pada tabel berikut

Tabel 1. Persebaran Anggota *Cluster*

Cluster	Banyaknya Anggota *Cluster*
1	640
2	581
3	189
4	1411
5	445

4.3. Hasil *Clustering* MT-DBSCAN (*Mix Type* DBSCAN)

Algoritma *Mix Type* DBSCAN atau DBSCAN Gower distance menggabungkan algoritma Hierarchical Gower *distance* untuk mengatasi mix type data dengan DBSCAN sendiri untuk mengatasi data outliers. Pada kasus ini, data dengan outliers dan tanpa outliers dianalisis dengan metode yang sama untuk dibandingkan sensitivitasnya.

4.3.1 MT-DBSCAN tanpa *Outliers* Data

Algoritma DBSCAN dengan Gower distance memerlukan parameter epsilon dan minimum sample sebagai penetuan awal. Penentuan nilai epsilon yang paling optimum disini dengan menggunakan bantuak K-NN atau K-Nearest Neighbour, dimana banyaknya K yang digunakan ialah 5. Berikut merupakan plot K-NN dari data dengan *outliers*.

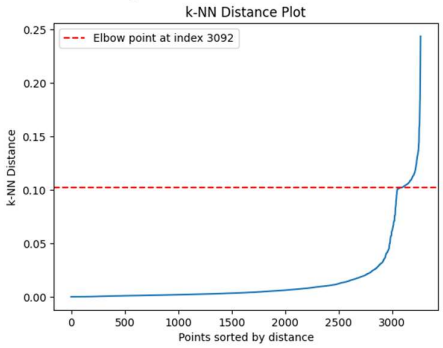

Gambar 6. K-NN untuk Menentukan Epsilon Pada Data dengan Outliers.

Visual pada gambar 6 menunjukkan rentang nilai epsilon. Dapat diketahui bahwa nilai epsilon berada pada nilai 0,102. Nilai inilah yang akan digunakan untuk algoritma DBSCAN dengan Gower distance. Minimum sampel yang digunakan sebanyak 10 sampel didapatkan hasil 2 *cluster* dengan masing-masing *cluster* memiliki anggota customer sebagai berikut.

Tabel 1. Persebaran Anggota *Cluster*

Cluster	Banyaknya Anggota *Cluster*
1	2545
2	527

3	294

Berdasarkan tabel 1 dapat dilihat bahwa banyaknya anggota yang tersebar dengan metode DBSCAN algoritma Gower distance didominasi pada *cluster* 1 dengan 2545 customer berada pada segment ini.

4.3.2 MT-DBSCAN dengan Outliers Data

Setelah melakukan analisis *cluster* dengan metode *Mix Type* DBSCAN atau DBSCAN dengan algoritma Gower distance dengan melibatkan data yang *outliers*, dengan cara yang sama, dibandingkan dengan data tanpa outliers untuk melihat mana yang lebih baik mengingat tujuan digunakan metode ini ialah karena data yang digunakan campuran antara data kategorik dan numerik serta bisa fleksibel terhadap *outliers* dari pada algoritma K. Berikut merupakan penentuan nilai epsilon yang digunakan dengan K-NN dimana K sama dengan 5.

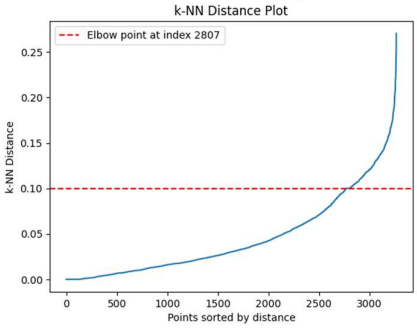

Gambar 7. Distance Plot untuk Penetuan Epsilon

Berdasarkan gambar 7 dapat diketahui bahwa nilai epsilon berada disekitar 0,107 dengan minimum sampel yang sama pada algoritma MT-DBSCAN dengan *outliers* yaitu sebesar 10 *sample* didapatkan hasil *cluster* sebanyak 11 *cluster* dengan rincian sebagai berikut.

Tabel 2. Karakteristik Setiap *Cluster* untuk Seluruh Variabel

Cluster ke	Banyaknya Anggota *Cluster*
1	385
2	493
3	2388

Berdasarkan hasil algoritma DBSCAN dengan Gower *distance* didapatkan hasil bahwa banyaknya anggota *cluster* didominasi oleh *cluster* ke 3 dengan anggota sebanyak 2388 customer. Perbandingan Metode

Salah satu metode pembanding untuk metode *cluster*ing yang interpretable ialah *average silhoute score*. Selain kelebihannya yang mudah diinterpretasikan, *metric* ini cukup baik untuk mengevaluasi metode yang melibatkan algoritma kepadatan (density based). Berikut merupakan perbandingan *average* silhoute score pada metode K-prototype dan Mix Type DBSCAN.

Tabel 3. Karakteristik Setiap *Cluster* untuk Seluruh Variabel

Outliers	K-Prototype	MT-DBSCAN
Ya	0, 21	0,52
Tidak	0, 41	0,33

Berdasarkan tabel 3 diatas dapat diketahui bahwa model terbaik yang didapat jika menggunakan average silhoute score ialah dengan metode MT-DBSCAN dengan membiarkan outliersnya dimana *cluster* yang terbentuk ialah sebanyak 3. Namun pada kasus dimana data outliers diatasi, metode K-prototype lebih baik dibandingkan MT-DBSCAN pada kasus ini. Perlu diingat bahwa pada kasus lain hasil bisa menjadi berbeda. Ini bisa terjadi dikarenakan faktor-faktor lain diluar hal yang diamati.

4.4. Hasil *Clustering* dengan Metode Terbaik Data Tanpa Outliers dan Dengan Outliers

Setelah membandingkan dengan menggunakan nilai *average* silhoute *score* hasil visualisasi dengan melibatkan data outliers dan data outliers masing-masing akan divisualisasikan pada sub bab berikut.

4.5.1 Hasil *Cluster*ing Tanpa Outliers dengan K-Protoype

Pada kasus ini, data frame yang digunakan ialah data tanpa outliers atau setelah di *winsorizing* sehingga menghasilkan *cluster* dengan karakteristik sebagai berikut.

Tabel 4. Karakteristik Setiap *Cluster* untuk Seluruh Variabel

Variabel		**Karakteristik *Cluster* 1**	**Karakteristik *Cluster 2***
Jenis Pesanan	Modus	Normal	Normal
Channel		Ijo	Ijo
Nama Toko		Toko 1	Toko 1
Provinsi		DKI Jakarta	DKI Jakarta
Total Penjualan	Mean	Rp 112.035	Rp.371.775
Total Berat		366,6(g)	960,4(g)
Potongan Ongkir		Rp 14.289	Rp 21.903
Voucher Channel		Rp 2.972	Rp 9.956
Diskon Penjual		Rp 1.969	Rp 9.064

Karakteristik masing-masing *cluster* yang tercantum pada Tabel 1 menunjukan bahwa customer pada *cluster* 1 merupakan customer dengan rata-rata pembelian lebih kecil dibandingkan dengan customer pada *cluster* 2. Sehingga mengakibatkan total berat pembelian customer pada *cluster* 1 lebih ringan dibandingkan dengan total berat pembelian customer pada *cluster* 2. Customer pada *cluster* 2 lebih banyak menggunakan potongan ongkir, voucher channel, dan diskon penjual dibandingkan dengan customer pada

cluster 1. Sehingga, customer pada *cluster* 1 dapat dijuluki *Loyal Customers* dan customer pada *cluster* 2 merupakan *Big Spenders*.

Untuk melihat masing-masing karakteristik *cluster* setelah mengetahui banyak *cluster* yang terbentuk, maka dapat dilakukan analisis secara deskriptif kembali untuk segmentasi pelanggan.

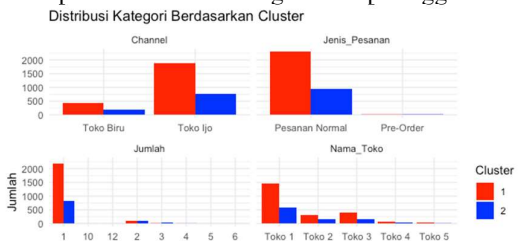

Gambar 8. Karakteristik Setiap *Cluster* untuk Variabel Categorik

Gambar 4 mennunjukkan bahwa secara umum menunjukkan perilaku yang sama untuk customer pada *cluster* 1 dan *cluster* 2. Dapat dilihat pada variabel Channel baik di toko Biru dan Hijau, persebaran *cluster* 1 lebih dominan dibandingkan *cluster* 2. Pada variabel jenis pesanan, pesanan normal memiliki persebaran yang dominan oleh *cluster* 1 sedangkan pada pesanan pre-order keduanya memiliki jumlah yang hampir sama. Sedangkan pada persebaran aktivitas pembelian di Toko 1 sampai Toko 5 juga memiliki persebaran yang sama dimana customer pada kelompok 1 dominan dala frekuensi jumlah pembelian.

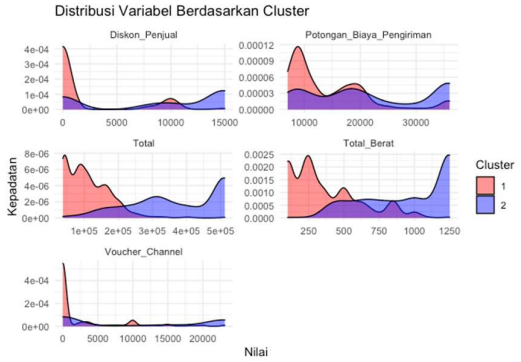

Gambar 9. Karakteristik Setiap *Cluster* untuk Variabel Numerik

Persebaran masing-masing *cluster* pada Gambar 5 dibedakan kedalam 2 warna dimana *cluster* 1 ialah *chart* berwarna merah dan *cluster* 2 *chart* berwarna biru. Secara umum, pada variabel numerik dapat dilihat bahwa *cluster* 1 memiliki jumlah total yang rendah secara nominal namun kelompok ini memiliki frequency yang tinggi atau dengan kata lain customer di kelompok 1 merupakan "*Loyal Customers*" / "*Frequent Visitors*". Sedangkan kelompok pada *Cluster* 2 secara transaksi tidak sebanyak customer pada *cluster* 1 namun secara nilai transaksi lebih besar dari *cluster* 1 sehingga consumen pada *cluster* ini merupakan "*Big Spanders*". Dengan demikian, karakteristik kesuluruhan dari *cluster* 1 dan 2 secara umum digambarkan pada tabel berikut.

Gambar 10. 10 Provinsi dengan Jumlah Pelanggan Terbanyak Pada Tiap *Cluster*

Pada Gambar 6 menjelaskan 10 provinsi dengan jumlah pelanggan terbanyak. Terlihat bahwa Provinsi DKI Jakarta memiliki pelanggan terbanyak baik pada *cluster* 1 dan *cluster* 2 dengan jumlah pelanggan berturut – turut adalah 250 dan 800 pelanggan. Kemudian, pada urutan 10 Provinsi Kepulauan Riau dimana masing – masing *cluster* memiliki pelanggan kurang dari 50.

4.5.2 Hasil Visualisasi Data dengan Outliers dengan Metode Terbaik Mix Type DBSCAN

Hasil *clustering* variabel numerik dengan algoritma MT-DBSCAN ditampilkan pada gambar berikut:

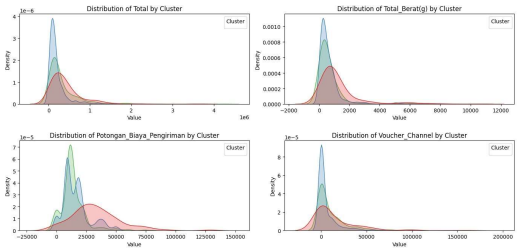

Gambar 11. *Clustering* variabel numerik MT-DBSCAN

Pada Gambar 8 menjelaskan karakteristik untuk masing – masing variabel numerik. *Cluster* 2 yang digambarkan oleh warna biru merupakan *cluster* dengan ciri pelanggan *Big Spander* karena secara transaksi tidak sebanyak cluster lain. Kemudian *cluster* 1 yang digambarkan dengan warna merah merupakan pelanggan dengan ciri *Loyal Customer* karena terlihat memiliki transaksi terbanyak dibandingkan yang lain namun secara nominal belanja tidak sebanyak pelanggan yang lain. Pada *cluster* 3 merupakan *cluster* yang secara frekuensi berbelanja dan nominal terletak diantara *cluster* 1 dan

cluster 2. Kemudian untuk hasil *clustering* variabel kategorik digambarkan pada Gambar 12.

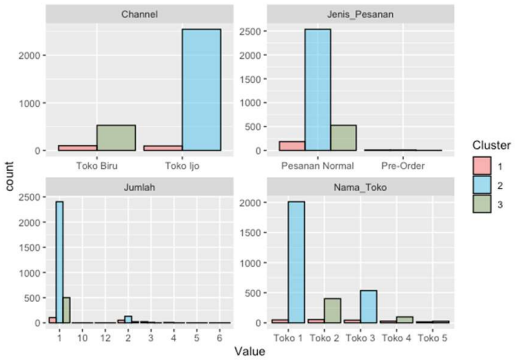

Gambar 12. *Clustering* variabel kategorik MT-DBSCAN

Pada gambar 9 terlihat sama dengan hasil *clustering* pada variabel numerik dimana *cluister* 1 merupakan *loyal customer, cluster* 2 merupakan pelanggan dengan ciri *big spander,* dan *cluster* 3 terletak diantara *cluster* 1 dan *cluster* 2. Pada variabel provinsi, disajikan pada grafik berikut dengan mevisualisasikan 10 provinsi tertinggi dengan jumlah terbanyak.

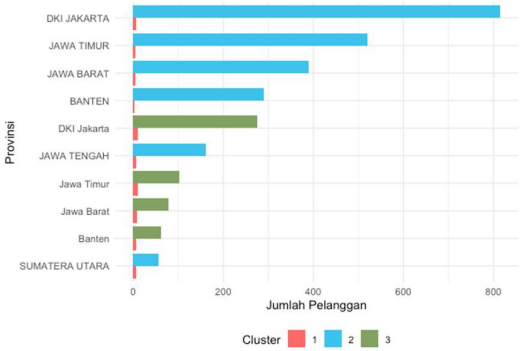

Gambar 13. *Clustering* variabel kategorik MT-DBSCAN

Pada gambar 10 terlihat bahwa provinsi DKI Jakarta memiliki jumlah pelanggan terbanyak yang mana pelanggan dengan ciri *cluster* 2 mendominasi. Kemudian pada peringkat kedua Provinsi Jawa Timur dengan pelanggan terbanyak dengan didominasi oleh pelanggan ciri *cluster* 2. Pada 10 Provinsi tersebut *cluster* 2 mendominasi di 6 provinsi, *cluster* 3 mendominasi 4 *cluster*.

5. KESIMPULAN DAN SARAN

Data mengandung outliers dapat dikelompokan menggunakan metode MT-DBSCAN dengan banyak cluster yang terbentuk ialah 3 cluster. Metode MT-DBSCAN merupakan metode yang lebih baik jika data yang digunakan terdapat outliers, hal tersebut dikarenakan pada algoritma MT-DBSCAN menggunakan Gowers *Distance* yang robust terhadap outliers. Sedangkan, jika outliers dalam data diatasi atau data tidak mengandung outliers maka metode clustering yang lebih baik adalah K-Protoype dengan banyak cluster yang terbentuk ialah 2 cluster.

Pada kasus ini, customer Perusahaan X dapat dikelompokkan menjadi tiga kelompok (*cluster*) dengan tujuan agar segmentasi customer lebih spesifik dan rekomendasi kepada Perusahaan lebih tepat sasaran. *Cluster* 1 merupakan customer dengan Tingkat loyalitas dan frekuensi mengunjungi platform channel e-commerce yang tinggi (*Loyal Customers*). Rekomendasi kebijakan untuk Perusahan X terkait dengan customer pada *cluster* 1 yakni

- Memberikan penawaran diskon ekslusif untuk pelanggan setia
- Membuat program loyalitas yang dapat memberikan insentif kepada pelanggan untuk terus belanja (misal, memberikan poin untuk setiap transaksi)
- Memberikan reward kepada pelanggan setia berupa penghargaan khusus, seperti voucher potongan harga pada event tertentu misalnya pada tanggal kembar atau hari besar.
- Menawarkan keanggotaan premium dengan manfaat tambahan, seperti tim layanan prioritas untuk mengatasi kendala dalam transaksi

C*luster* 3 merupakan customer dengan jumlah pembelian yang sangat tinggi (*Big Spenders)*. Rekomendasi kebijakan untuk Perusahaan X terkait dengan customer pada *cluster* 3 yakni

- Membuat program keanggotaan VIP yang menawarkan keuntungan eksklusif seperti akses awal produk baru dan penawaran khusus yang tidak tersedia untuk pelanggan non-VIP.
- Menawarkan layanan *personal concierge* yang dapat membantu sesuai kebutuhan spesifik customer. Layanan ini bisa berupak bantuan pembelian, rekomendasi produk, dan penanganan keluhan atau permintaan khusus.
- Memberikan hadiah premium, dapat berupa produk mewah atau voucher belanja dengan nilai tinggi

Cluster 2 merupakan customer dengan Tingkat loyalitas yang lebih tinggi dibandingkan *cluster* 1 namun tidak setinggi *cluster* 3. Rekomendasi kebijakan untuk Persahaan X terkait dengan customer pada *cluster* 2 yakni

- Membuat program keanggotaan premium yang memberikan penawaran khusus dan tidak tersedia untuk pelanggan kelas dibawahnya.

- Menawarkan layanan pelanggan premium seperti tim dukungan khusus, hotline khusus, atau layanan prioritas penanganan masalah.
- Melakukan *engagement* yang aktif dengan melibatkan customer pada *cluster* ini secara aktif melalui survei, feedback, atau diskusi langsung untuk mendapatkan masukan dan saran.

6. DAFTAR PUSTAKA

CORMEN, T. H., LEISERSON, R. L., & RIVEST, C. S. (2001). Introduction to Algorithms. *The MIT Press*.

DAKE, D. K., GYIMAH, E., BUABENG-ANDOH, C., & RAJINIKANTH, V. (2023). University Students Behaviour Modelling Using the K-Prototype Clustering Algorithm. *Mathematical Problems in Engineering*, *2023*. https://doi.org/10.1155/2023/5507814

DASH, C. S. K., BEHERA, A. K., DEHURI, S., & GHOSH, A. (2023). An outliers detection and elimination framework in classification task of data mining. *Decision Analytics Journal*, *6*. https://doi.org/10.1016/j.dajour.2023.100164

ERILLI, N. A. (2019). Comparison of fuzzy clustering methods in economic freedom ranking in Asia-Pacific. In *Jurnal Perspektif Pembiayaan dan Pembangunan Daerah* (Vol. 7, Issue 2).

FADILAH, Z. R., & WIJAYANTO, A. W. (2023). Perbandingan Metode Klasterisasi Data Bertipe Campuran: One-Hot-Encoding, Gower Distance, dan K-Prototype Berdasarkan Akurasi (Studi Kasus: Chronic Kidney Disease Dataset). In *Journal of Applied Informatics and Computing (JAIC)* (Vol. 7, Issue 1). http://jurnal.polibatam.ac.id/index.php/JAIC

HUANG, Z. (1998). Extensions to the k-Means Algorithm for Clustering Large Data Sets with Categorical Values. In *Data Mining and Knowledge Discovery* (Vol. 12).

KAUFMAN, L., & ROUSSEEUW, P. J. (2005). *Finding Groups in Data*. John Wiley & Sons.

NOVIDIANTO, R., & FITHRIASARI, K. (2021). Algoritma ClusterMix K-Prototypes Untuk Menangkap Karakteristik Pasien Berdasarkan Variabel Penciri Mortalitas Pasien Dengan Gagal Jantung. *Inferensi*, *4*(1), 37. https://doi.org/10.12962/j27213862.v4i1.8479

SIHOMBING, P. R., SURYADININGRAT, S., SUNARJO, D. A., & YUDA, Y. P. A. C. (2023). Identifikasi Data Outlier (Pencilan) dan Kenormalan Data Pada Data Univariat serta Alternatif Penyelesaiannya. *Jurnal Ekonomi Dan Statistik Indonesia*, *2*(3), 307–316. https://doi.org/10.11594/jesi.02.03.07

XU, R., & WUNSCH, D. (2005). Survey of clustering algorithms. In *IEEE Transactions on Neural Networks* (Vol. 16, Issue 3, pp. 645–678). https://doi.org/10.1109/TNN.2005.845141